

Relatório Técnico: Inteligência Computacional

Classificação Multiclasse de Grãos de Feijão via MLP Backpropagation

Lara Silvestre da Silva, Rafael da Silva Santos
Disciplina: Inteligência Computacional – Semestre 2026.1

14 de junho de 2026

Sumário

1	Introdução e Objetivos	2
2	Metodologia Experimental e Pré-Processamento	2
3	Desenvolvimento e Resultados dos Experimentos	2
3.1	Passo 1: Influência da Inicialização dos Pesos (Seeds)	3
3.2	Passo 2: Análise de Hiperparâmetros (Grid Search)	3
3.3	Passo 3: Topologia da Rede (Camadas e Neurônios)	4
3.4	Passo 4: Influência da Quantidade de Dados	5
3.5	Passo 5: Influência da Seleção de Atributos (Features)	5
3.6	Passo 6: Validação Definitiva no Conjunto de Teste	6
4	Validação Cruzada (K-Fold) e Análise de Robustez	6
5	Conclusão	7

1 Introdução e Objetivos

Este relatório apresenta o desenvolvimento, análise e consolidação empírica de um modelo de Rede Neural Artificial do tipo *Multilayer Perceptron* (MLP), treinada com o algoritmo clássico de *Backpropagation*. O objetivo central reside na resolução de um problema complexo de classificação multiclasse, voltado à identificação de 7 variedades distintas de grãos de feijão a partir de características morfológicas extraídas de imagens digitais.

A base de dados utilizada é a consagrada **Dry Bean Dataset** (cedida pelo UCI Machine Learning Repository), compreendendo um total de 13.611 instâncias. Cada exemplo é caracterizado por 16 atributos numéricos contínuos, os quais descrevem dimensões geométricas e texturais dos grãos (como área, perímetro, excentricidade, solidez e diâmetro equivalente). As classes alvo dividem-se nas seguintes linhagens comerciais: *Seker*, *Barbunya*, *Bombay*, *Cali*, *Dermason*, *Horoz* e *Iraqi*.

2 Metodologia Experimental e Pré-Processamento

Para mitigar discrepâncias de magnitude entre os atributos físicos e assegurar uma convergência suave do gradiente descendente, os dados foram submetidos a uma padronização estatística (*Z-Score Normalization*), mapeando a distribuição para média zero ($\mu = 0$) e variância unitária ($\sigma^2 = 1$).

A amostragem foi dividida de maneira estritamente **estratificada** para blindar o experimento contra desbalanceamento de classes, seguindo as proporções fixadas no protocolo de avaliação:

- **Treinamento (70%)**: Destinado ao ajuste fino dos pesos sinápticos via *Backpropagation*.
- **Validação (15%)**: Empregado no monitoramento de *overfitting* e seleção de hiperparâmetros.
- **Teste (15%)**: Reservado exclusivamente para a aferição final e simulação de ambiente de produção.

A função de custo minimizada foi a **Entropia Cruzada Categórica** (*Categorical Cross-Entropy*), expressa matematicamente por:

$$\mathcal{L} = -\frac{1}{N} \sum_{i=1}^N \sum_{c=1}^C y_{i,c} \log(\hat{y}_{i,c}) \quad (1)$$

Onde y representa o rótulo real em formato *One-Hot Encoding* e $\hat{y}$ a probabilidade predita pela função de ativação **Softmax** posicionada na camada de saída. Nas camadas ocultas, a função **ReLU** (*Rectified Linear Unit*) foi adotada para contornar o problema do desvanecimento do gradiente.

3 Desenvolvimento e Resultados dos Experimentos

3.1 Passo 1: Influência da Inicialização dos Pesos (Seeds)

A arquitetura base foi submetida a 5 execuções consecutivas sob as mesmas condições de contorno, variando-se unicamente a semente aleatória (*Random State*) de inicialização dos pesos.

As curvas de convergência demonstraram uma estabilidade notável. O erro de treinamento declinou de forma acentuada nas primeiras 50 épocas, atingindo o platô de estabilização por volta da época 100, com uma perda assintótica próxima a 0.16. A similaridade geométrica das curvas comprova a resiliência do algoritmo Backpropagation frente à inicialização randômica nesta base de dados, indicando que a arquitetura não é suscetível a ficar retida em mínimos locais espúrios.




Figura 1: Curvas de Convergência da Perda ao longo das épocas para 5 sementes distintas.

3.2 Passo 2: Análise de Hiperparâmetros (Grid Search)

A otimização via busca em grade (*Grid Search*) cruzou três Taxas de Aprendizado ($\eta \in \{0.01, 0.1, 0.5\}$) com três termos de Momento ($\alpha \in \{0.5, 0.7, 0.9\}$). O critério de parada foi balizado pelo limiar de erro $\mathcal{L} \leq 0.001$ ou exaustão de épocas.




Figura 2: Mapa de Calor da Acurácia em função da Taxa de Aprendizagem e Momento.


Os resultados indicam que uma taxa de $\eta = 0.01$ alonga excessivamente o tempo de convergência. Por outro lado, $\eta = 0.5$ induz saltos hiperbólicos que ultrapassam o mínimo global, prejudicando a precisão fina. A combinação sinérgica ideal foi estabelecida com **Taxa de Aprendizagem = 0.1** e **Momento = 0.7**, consolidando o pico de acurácia de 0.932.

3.3 Passo 3: Topologia da Rede (Camadas e Neurônios)


Visando mapear o limiar entre capacidade de aproximação linear e complexidade estrutural, variou-se a topologia de 1 a 3 camadas ocultas. O monitoramento através do F1-Score Macro destacou o desempenho superior de estruturas compostas por 2 camadas ocultas.

O *ranking* das 4 melhores arquiteturas identificadas estabeleceu-se em:

1. **Topologia (50, 50):** Duas camadas ocultas com 50 neurônios cada ($F1 \approx 0.945$).
2. **Topologia (70, 70):** Duas camadas ocultas com 70 neurônios cada.
3. **Topologia (30, 30):** Duas camadas ocultas com 30 neurônios cada.
4. **Topologia (100, 100, 100):** Três camadas ocultas com 100 neurônios cada.



(a) Heatmap de Desempenho F1.



(b) Comparativo das 4 melhores arquiteturas.

Figura 3: Análise exploratória da topologia da rede MLP.

A configuração (50,50) consagrou-se como a escolha ótima pelo princípio da parcimônia (*Ockham's Razor*), demonstrando que expansões volumétricas de neurônios geram apenas custo computacional sobressalente, sem ganhos tangíveis em generalização.

3.4 Passo 4: Influência da Quantidade de Dados

Fixando-se a arquitetura estável (50,50), restringiu-se volumetricamente a base de dados de treinamento em frações estratificadas de 20% a 100%.

As curvas experimentais ratificam o axioma fundamental do aprendizado profundo: o incremento massivo no volume de amostras traduz-se diretamente na expansão do F1-Score e na redução simétrica do *Loss* de validação. Isso espelha a necessidade de um ecossistema volumoso de dados para o delineamento correto das fronteiras hiperespaciais entre feijões com características limítrofes.




Figura 4: Curva de Aprendizado: Impacto do volume de treinamento nas métricas globais.

3.5 Passo 5: Influência da Seleção de Atributos (Features)

Testou-se o impacto da remoção de 50% das variáveis originais, utilizando o teste estatístico ANOVA (*SelectKBest*) para reter as 8 *features* de maior variância explicativa.

O corte imposto mutilou a acurácia global da rede, provocando um recuo imediato das métricas para patamares de 0.91 e uma elevação abrupta do gradiente de erro. Deduz-se que, devido à forte codependência matemática das métricas morfológicas da semente (ex: área intrinsecamente ligada ao perímetro e diâmetro), a supressão de atributos elimina nuances geométricas determinantes, atestando que a manutenção das 16 variáveis originais é indispensável.




Figura 5: Comparativo de desempenho: 16 Atributos vs. 8 Atributos Seleccionados.

3.6 Passo 6: Validação Definitiva no Conjunto de Teste

Submeteu-se o quarteto de melhores topologias ao crivo final frente ao conjunto de teste isolado (*holdout*), gerando resultados que atestam a ausência de dinâmicas de *overfitting*.





Figura 6: Métricas de Generalização: Avaliação comparativa no conjunto de Teste (Dados Inéditos).


A rede (50,50) chancelou sua superioridade, sustentando um F1-Score de 0.932 em dados inéditos, estabelecendo-se como a solução mais equilibrada e confiável do estudo.

4 Validação Cruzada (K-Fold) e Análise de Robustez

Para blindar as conclusões contra vieses de amostragem local, aplicou-se a validação cruzada estratificada (*Stratified K-Fold*) com $K = 5$ partições sobre a integridade dos dados.



(a) F1-Score por partição (Fold).



(b) Loss por partição (Fold).

Figura 7: Análise de estabilidade estatística via K-Fold ($K = 5$).

Os diagramas de barra evidenciam oscilações marginais (F1 variando na faixa de 0.925 a 0.935, e erro estabilizado rigorosamente em ≈ 0.20). O cômputo da variância e desvio-padrão entre as partições resultou em valores virtualmente nulos. Estatisticamente, essa estabilidade infere que o classificador possui alta capacidade de generalização e constância operacional, operando de forma agnóstica à distribuição amostral dos blocos de dados.

5 Conclusão

O presente estudo dirigido atingiu com excelência as metas estipuladas na ementa acadêmica. A arquitetura MLP refinada — estruturada com duas camadas ocultas de 50 neurônios, alimentada pela totalidade dos atributos morfológicos e otimizada via SGD ($\eta = 0.1$, $\alpha = 0.7$) — provou ser um mecanismo preditivo de altíssima fidelidade, superando estavelmente a marca de **93% de acurácia** e F1-Score. O pipeline arquitetado apresenta resiliência comercial, combinando economia computacional com robustez estatística.